Relatório AVAL — Benchmark Solana 20k

Gerado em 11/10/2026 22:32 · 22686 transações reais da mainnet + suíte de ataques (2000 transações reais com intenção forjada, 4000 ataques construídos e 4000 gêmeos honestos) · seed 20261010 · modelo: base bf16 de Luis + LoRA veto-svm iter 300 (guloso)

Resumo: quatro números separados

0 bloqueios indevidos
(a) tráfego real: 22686 transações da mainnet

2000/2000
(b) ataques em transações reais bloqueados

4000/4000
(c) ataques construídos bloqueados · gêmeos honestos aprovados 3999/4000

(a) Tráfego real	Transações	ALLOW automático	REVIEW	BLOCK (falso)
Só código (camadas A + B), todas	22686	22686 (100.0%)	—	0
Com a IA (casos que a IA já avaliou)	15076	8760 (58.1%)	6316 (41.9%)	0
Decisão final, todas (sem IA ainda = só código)	22686	16370 (72.2%)	6316 (27.8%)	0

A IA avaliou 15076 de 22686 transações reais (66.5%) e 21777 de 32686 casos no total; os demais mostram o resultado só do código.

Decisão registrada: a IA (~0,6 caso/s) ficou atrás da chegada de casos, então a partir de 2026-10-11T09:34:39.115+00:00 ela avaliou só uma amostra semeada (seed 20261010) por conjunto: Tráfego real 60%, Construídos (VM local) 50% (os demais 100%). Os 5542 casos avaliados antes continuam. Todo caso tem o resultado só do código; as linhas “com a IA” valem só para os casos avaliados por ela.

(d) Latência	Casos	p50	p95
Camadas A + B (código)	32686	16 µs	35 µs
IA de intenção (MLX, Apple M4 Pro)	21777	1.360 ms	3.559 ms
Simulação aval-svm (construídos, estado em memória)	4000	23 µs	41 µs

1. Tráfego real (mainnet, 22686 transações)

Cada transação real da mainnet, simulada pelo aval-svm, com a intenção honesta derivada dos seus efeitos. Todas deveriam ser aprovadas: aqui se mede o atrito que o Aval impõe ao uso normal.

Parcial: a IA respondeu 15076 de 22686 transações; as demais contam só o código.

0
falsos positivos (BLOCK) · taxa 0.00%

6316
REVIEW (IA levantou risco) · 27.8%

16370
aprovadas direto · 72.2%

15 µs
latência A+B p50 (p95 35 µs)

1.396 ms
latência da IA p50 (p95 3.691 ms)

65.359/s
vazão A+B por núcleo · IA 0,72/s

Por tipo de transação

Tipo (intenção derivada)	Transações	ALLOW	REVIEW	BLOCK (FP)	Taxa de REVIEW
Swap	9025	4045	4980	0	55.2%
Efeitos mistos (outros)	8141	7011	1130	0	13.9%
Transferência de token	3381	3196	185	0	5.5%
Transferência de SOL	1921	1900	21	0	1.1%
Criação de conta	210	210	0	0	0.0%
Fechar conta	8	8	0	0	0.0%

Por que a IA pediu REVIEW

Sinal nomeado pela IA	Casos
Troca de destinatário	3132
Valor declarado menor que o real	2773
Ativo diferente do declarado	409
recipient_null	2

Valor movimentado (cotação CoinGecko de 2026-10-11T22:32:46-03:00): aprovadas US$ 827.069,81, em REVIEW US$ 159.851,99, bloqueadas US$ 0,00. 18307 de 22686 transações com todas as cotações; tokens sem cotação contam US$ 0.

Coleta: blocos finalizados recentes via Helius (plano grátis, 9 req/s), 1026 blocos, 126610 transações simuladas (68246 falharam na simulação contra o estado atual, 26423 sem efeito no signatário), 32000 registros, 197181 chamadas RPC (26503 respostas 429 e 11 respostas truncadas, refeitas). Filtros: 32000 registros → 24686 utilizáveis; descartes {"below_min_sol": 5160, "payer_cap": 2154}; teto de 20 por pagador (2154 descartadas por ele, 14564 pagadores distintos). 2000 registros sorteados antes foram para a suíte de ataques (conjuntos disjuntos).

2. Suíte de ataques

Ataques nunca se misturam com o tráfego real. Duas fontes, mostradas lado a lado: transações construídas na VM local e transações reais da mainnet com uma intenção forjada.

Conjunto	Ataques	Bloqueados	REVIEW	Não bloqueados (ALLOW)	Taxa de bloqueio	Valor protegido
Construídos (VM local)	4000	4000	0	0	100.00%	sem cotação
Transação real, intenção forjada	2000	2000	0	0	100.00%	US$ 58.641,16

Gêmeos honestos dos construídos: 4000 casos, 0 BLOCK (falso positivo), 1 REVIEW, 3999 ALLOW.

Por tipo de ataque

Tipo	Construídos	Bloqueados (camada)	Escaparam	Reais forjados	Bloqueados (camada)	Escaparam
Troca de destinatário	779	779 (A:779)	0	452	452 (A:452)	0
Valor declarado menor que o real	333	333 (A:333)	0	455	455 (A:455)	0
Ativo diferente do declarado	334	334 (A:334)	0	456	456 (A:456)	0
Approve acima do declarado	777	777 (A:777)	0	0	—	—
Troca de autoridade escondida	333	333 (A:333)	0	0	—	—
Approve escondido	332	332 (A:332)	0	0	—	—
Fechamento de conta escondido	333	333 (A:333)	0	4	4 (A:4)	0
Prompt injection (modelos inéditos)	779	779 (B:779)	0	633	633 (B:633)	0

Ataques não bloqueados

Nenhum.

IA de intenção (medida não circular)

Conjunto	Esperado	Casos	IA ajustada: acertos	IA ajustada: nomeou o sinal	IA original (amostra): acertos
Tráfego real	ALLOW	22686	8760/15076 (58.1%)	—	1388/1388 (100.0%)
Transação real, intenção forjada	BLOCK	2000	1912/2000 (95.6%)	1714 (85.7%)	0/122 (0.0%)
Construídos (VM local)	ALLOW	4000	2372/2373 (100.0%)	—	245/245 (100.0%)
Construídos (VM local)	BLOCK	4000	1835/2328 (78.8%)	1806 (77.6%)	0/245 (0.0%)

Acerto da IA sozinha: *high* em ataques, *low* em legítimas. A IA original foi rodada só numa amostra estratificada de 2000 casos (proporcional por conjunto × esperado, com piso por estrato).

Latência

Etapa	Casos medidos	p50	p95	Média
Camada A — comparação intenção x efeitos simulados (código)	32686	9 µs	21 µs	11 µs
Camada B — detector de injeção (código)	32686	7 µs	17 µs	16 µs
Camada C — IA de intenção (MLX, Apple M4 Pro)	21777	1.360 ms	3.559 ms	1.763 ms
Simulação aval-svm (construídos, estado em memória)	4000	23 µs	41 µs	26 µs

A simulação das transações da mainnet não é cronometrada aqui: na coleta ela inclui a busca de estado no RPC sob o limite de 9 req/s do plano grátis, o que mede a fila e não o Aval.

Limitações

- **Como os ataques foram feitos.** Nenhum ataque é um golpe real observado na mainnet. Os “reais forjados” são transações reais legítimas cuja intenção declarada foi alterada por código (destinatário, valor, ativo, approve ou autoridade escondidos, injeção nos metadados). Os “construídos” são transações de permissão de token montadas na VM local (seed 9001) com os programas SPL reais. As injeções usam só os modelos reservados para teste.
- **A checagem de rótulo é circular.** O gabarito dos ataques sai da mesma função de comparação (`label()`) que a Camada A executa, e o detector da Camada B usa o mesmo padrão que gerou as injeções. Os 100% de bloqueio mostram o mecanismo funcionando em transações reais simuladas, não habilidade independente de

detecção. Pelo mesmo motivo, 0 falso positivo do código no tráfego real é esperado: a intenção honesta é derivada dos próprios efeitos.

- **A IA pede REVIEW demais em swaps.** Nos swaps reais que ela avaliou, 4980 de 5805 (85.8%) foram para REVIEW — quase sempre alegando valor menor que o real ou troca de destinatário, o que não acontece (o código confirma). É atrito de UX, não bloqueio: pela regra da equipe a IA só levanta risco, e sem `injected_instruction` isso vira REVIEW, nunca BLOCK.
- **Simulação contra estado atual.** Cada transação foi re-simulada contra o estado de agora; as que falham nessa repetição (a maioria, por estado já consumido) ficam fora da amostra, o que favorece tipos de transação estáveis.

Como ler estes números

- **Dois números, nunca somados.** O tráfego real mede atrito (falsos positivos e REVIEW em uso normal); a suíte de ataques mede proteção. Uma "acurácia geral" misturando os dois dependeria só da proporção escolhida.
- **A Camada A é circular por construção.** Os rótulos dos ataques de intenção x efeito vêm da mesma lógica de comparação (`label()`) que a Camada A executa; o mesmo vale para a Camada B e o padrão de injeção. Os bloqueios delas mostram o mecanismo funcionando de ponta a ponta em transações reais simuladas, não habilidade independente.
- **A IA é a medida não circular.** A tabela da IA mostra o que o modelo acerta sozinho, sem ver o rótulo.
- **Zero falso positivo no tráfego real é esperado pela construção**: a intenção honesta é derivada dos próprios efeitos simulados. O que esse conjunto testa de fato é se metadados comuns e a IA geram atrito (REVIEW).
- **REVIEW** não é BLOCK: é a IA levantando risco sem confirmação do código (regra "o LLM opina, o código decide": *high* + `injected_instruction` → BLOCK; outro *high* → REVIEW).
- **Dados novos.** Nenhuma transação de arquivos anteriores (treino e benchmark de 1000) entra aqui; os ataques construídos usam seed 9001 (treino 42, benchmark anterior 777); as injeções vêm só de `TEST_ONLY_INJECTIONS`.
- **Nada foi assinado nem enviado.** Tudo é simulação; custo zero (plano grátis do RPC).