Relatório AVAL — Benchmark Solana (1000 transações)

Gerado em 09/10/2026 23:04 · 1000 casos · seed 20261009 · 400 mainnet / 600 sintéticas · modelo: base bf16 de Luis + LoRA veto-svm iter 300 (guloso)

Decisões: BLOCK x ALLOW

500
BLOCK · US$ 21.146,51 (só mainnet com cotação)

432
ALLOW · US$ 1.608,31

500 / 500
esperado BLOCK / ALLOW

	Casos	Obtido BLOCK	Obtido ALLOW	REVIEW (outros)
Ataques (deveriam ser BLOCK)	500	500	0	0
Legítimas (deveriam ser ALLOW)	500	0	432	68
Total	1000	**500**	**432**	68

Valor das transações

US$ 21.146,51
salvo: ataques bloqueados

US$ 0,00
teria sido roubado: ataques aprovados

US$ 0,00
legítimo bloqueado indevidamente

Grupo	Transações	Valor (US$)	Com cotação / sem cotação	Significado
Ataques bloqueados	500	US$ 21.146,51	183 / 317	valor protegido
Ataques em REVIEW	0	US$ 0,00	0 / 0	retido para revisão humana
Ataques aprovados	0	US$ 0,00	0 / 0	valor que teria sido roubado
Legítimas aprovadas	432	US$ 1.608,31	151 / 281	operação normal

Grupo	Transações	Valor (US$)	Com cotação / sem cotação	Significado
Legítimas em REVIEW	68	US$ 1.198,33	66 / 2	atrasado para revisão humana
Legítimas bloqueadas	0	US$ 0,00	0 / 0	valor travado indevidamente (falso positivo)

Cotações: ZEC US$ 1207.98, GOOGLX US$ 352.71, SPCX US$ 162.53, SOL US$ 108.72, PRIME US$ 1.063, USDC US$ 0.999697, USDT US$ 0.999229, CASH US$ 0.998983, JUPUSD US$ 0.998837, FO US$ 0.137669, VERSE US$ 0.0208629, SKR US$ 0.0164116, PUMP US$ 0.00540542, HIGGS US$ 0.0011996, FILLED US$ 0.00028689.

Valor = o que sai das contas do signatário na simulação (SOL + tokens, sem a taxa), na cotação CoinGecko de 2026-10-09T19:10:04-03:00 (SOL US$ 108.72; 14 de 55 mints da mainnet com cotação; 94 transações mainnet têm algum token sem cotação, contado como US$ 0). As 600 transações sintéticas usam mints criados na VM local, sem preço: aparecem como **sem cotação**, não são estimadas. Nada é assinado ou enviado.

Resumo geral

100.0%
acurácia do pipeline (REVIEW conta como não-BLOCK)

500/500
ataques bloqueados (100.0%)

0
ataques não bloqueados

0
falsos positivos finais (taxa 0.0%)

68
REVIEW (0 ataques, 68 legítimas)

0
erros de infraestrutura (1 respostas inválidas da IA)

Por tipo de ataque

Tipo	Classe	Casos	Corretos	Erros	Taxa de acerto	O que impediu / resultado	Latência média
Troca de destinatário	Ataque	87 8 main / 79 sint.	87	0	100.0%	Camada A: recipient_mismatch (87)	2.438 ms
Valor declarado menor que o real	Ataque	86 61 main / 25 sint.	86	0	100.0%	Camada A: amount_understated (86)	1.285 ms
Ativo diferente do declarado	Ataque	87 55 main / 32 sint.	87	0	100.0%	Camada A: asset_mismatch (87)	1.815 ms

Tipo	Classe	Casos	Corretos	Erros	Taxa de acerto	O que impediu / resultado	Latência média
Approve acima do declarado	Ataque	73 0 main / 73 sint.	73	0	100.0%	Camada A: approval_exceeds_intent (73)	1.387 ms
Troca de autoridade escondida	Ataque	25 0 main / 25 sint.	25	0	100.0%	Camada A: undeclared_authority_change (25)	1.772 ms
Approve escondido	Ataque	27 0 main / 27 sint.	27	0	100.0%	Camada A: undeclared_approval (27)	2.024 ms
Fechamento de conta escondido	Ataque	25 0 main / 25 sint.	25	0	100.0%	Camada A: undeclared_close (25)	1.219 ms
Prompt injection (modelos inéditos)	Ataque	90 59 main / 31 sint.	90	0	100.0%	Camada B: injeção nos metadados (90)	1.319 ms
Approve declarado	Legítimo	77 0 main / 77 sint.	77	0	100.0%	Aprovado (75) REVIEW: IA marcou risco alto (approval_exceeds_intent) (2)	808 ms
Fechar conta	Legítimo	46 0 main / 46 sint.	46	0	100.0%	Aprovado (46)	842 ms
Criação de conta	Legítimo	4 4 main / 0 sint.	4	0	100.0%	Aprovado (4)	878 ms
Efeitos mistos (outros)	Legítimo	81 81 main / 0 sint.	81	0	100.0%	Aprovado (76) REVIEW: IA marcou risco alto (recipient_mismatch) (5)	1.391 ms
SetAuthority declarado	Legítimo	51 0 main / 51 sint.	51	0	100.0%	Aprovado (51)	761 ms
Swap	Legítimo	65 65 main / 0 sint.	65	0	100.0%	REVIEW: IA marcou risco alto (amount_understated) (38) REVIEW: IA marcou risco alto (recipient_mismatch) (19) Aprovado (5) REVIEW: IA marcou risco alto (asset_mismatch) (3)	2.122 ms

Tipo	Classe	Casos	Corretos	Erros	Taxa de acerto	O que impediu / resultado	Latência média
Transferência de SOL	Legítimo	16 16 main / 0 sint.	16	0	100.0%	Aprovado (16)	704 ms
Transferência de token	Legítimo	160 51 main / 109 sint.	160	0	100.0%	Aprovado (159) REVIEW: IA marcou risco alto (recipient_mismatch) (1)	1.005 ms

Latência média = A + B + IA + simulação (simulação medida só nas sintéticas; ver Latência).

Por camada

Camada	Ataques: BLOCK	Ataques: REVIEW	Legítimas: BLOCK	Legítimas: REVIEW	Decidiu primeiro (A→B→C)	Ataques que só ela pegou
Camada A — Simulação + comparação determinística	410	0	0	0	410	121
Camada B — Detector de injeção	90	0	0	0	90	0
Camada C — IA de intenção	88	291	0	68	68	0

Regra "o LLM opina, o código decide": a IA só aumenta o risco. IA *high* com `injected_instruction` → BLOCK; *high* só com outros sinais → REVIEW (contado à parte, não é BLOCK); IA *low* nunca derruba um BLOCK de A ou B.

IA de intenção por sinal (medida não circular)

Tipo	Casos	IA ajustada: acertos	IA ajustada: nomeou o sinal	IA original: acertos
Troca de destinatário	87	87 (100.0%)	87 (100.0%)	0 (0.0%)
Valor declarado menor que o real	86	25 (29.1%)	15 (17.4%)	0 (0.0%)
Ativo diferente do declarado	87	79 (90.8%)	79 (90.8%)	0 (0.0%)
Approve acima do declarado	73	31 (42.5%)	31 (42.5%)	0 (0.0%)
Troca de autoridade escondida	25	25 (100.0%)	25 (100.0%)	0 (0.0%)
Approve escondido	27	27 (100.0%)	27 (100.0%)	0 (0.0%)

Tipo	Casos	IA ajustada: acertos	IA ajustada: nomeou o sinal	IA original: acertos
Fechamento de conta escondido	25	15 (60.0%)	15 (60.0%)	0 (0.0%)
Prompt injection (modelos inéditos)	90	90 (100.0%)	88 (97.8%)	0 (0.0%)
Approve declarado	77	75 (97.4%)	—	77 (100.0%)
Fechar conta	46	46 (100.0%)	—	46 (100.0%)
Criação de conta	4	4 (100.0%)	—	4 (100.0%)
Efeitos mistos (outros)	81	76 (93.8%)	—	81 (100.0%)
SetAuthority declarado	51	51 (100.0%)	—	51 (100.0%)
Swap	65	5 (7.7%)	—	65 (100.0%)
Transferência de SOL	16	16 (100.0%)	—	16 (100.0%)
Transferência de token	160	159 (99.4%)	—	160 (100.0%)

Baselines

Conjunto	Casos	VP	VN	FP	FN	Acurácia	Precisão	Recall	Taxa FP
Baseline always_allow	1000	0	500	0	500	0.5000	—	0.0000	0.0000
Baseline always_block	1000	500	0	500	0	0.5000	0.5000	1.0000	1.0000
Só a IA original (bf16 de Luis, high→BLOCK)	1000	0	500	0	500	0.5000	—	0.0000	0.0000
Só a IA ajustada (LoRA iter 300, high→BLOCK)	1000	379	432	68	121	0.8110	0.8479	0.7580	0.1360
Pipeline sem IA (A + B)	1000	500	500	0	0	1.0000	1.0000	1.0000	0.0000
Pipeline completo (A + B + C)	1000	500	500	0	0	1.0000	1.0000	1.0000	0.0000
Pipeline completo, REVIEW contado como BLOCK	1000	500	432	68	0	0.9320	0.8803	1.0000	0.1360

Por origem

Conjunto	Origem	Casos	VP	VN	FP	FN	Acurácia	Precisão	Recall	Taxa FP
Só a IA original (bf16 de Luis, high→BLOCK)	mainnet	400	0	217	0	183	0.5425	—	0.0000	0.0000
Só a IA original (bf16 de Luis, high→BLOCK)	synthetic	600	0	283	0	317	0.4717	—	0.0000	0.0000
Só a IA ajustada (LoRA iter 300, high→BLOCK)	mainnet	400	140	151	66	43	0.7275	0.6796	0.7650	0.3041
Só a IA ajustada (LoRA iter 300, high→BLOCK)	synthetic	600	239	281	2	78	0.8667	0.9917	0.7539	0.0071
Pipeline sem IA (A + B)	mainnet	400	183	217	0	0	1.0000	1.0000	1.0000	0.0000
Pipeline sem IA (A + B)	synthetic	600	317	283	0	0	1.0000	1.0000	1.0000	0.0000
Pipeline completo (A + B + C)	mainnet	400	183	217	0	0	1.0000	1.0000	1.0000	0.0000
Pipeline completo (A + B + C)	synthetic	600	317	283	0	0	1.0000	1.0000	1.0000	0.0000

Positivo = BLOCK. REVIEW conta como não-BLOCK, exceto na última linha. Respostas inválidas da IA contam como ALLOW (ajustada: 1, original: 67).

Latência

Camada	Casos medidos	p50	p95	Média
Simulação aval-svm (sintéticas, estado em memória)	600	30 µs	64 µs	41 µs
Camada A — Simulação + comparação determinística (código)	1000	5 µs	9 µs	6 µs
Camada B — Detector de injeção (código)	1000	4 µs	9 µs	4 µs
Camada C — IA de intenção (MLX, Apple M4 Pro)	1000	1.303 ms	2.495 ms	1.396 ms

Camada	Casos medidos	p50	p95	Média
Total por caso	1000	1.303 ms	2.495 ms	1.396 ms

A simulação das sintéticas foi refeita pelo motor do aval-svm (LiteSVM, programas SPL reais, estado em memória, sem rede) e cronometrada por transação. A latência de simulação das transações da mainnet não pode ser medida numa reexecução "quente": o estado on-chain já mudou desde a amostragem, então não é reportada. A e B são código Python puro; C é a chamada do modelo (geração gulosa, até 200 tokens).

Casos não detectados e falsos positivos

0
ataques não bloqueados (BLOCK)

0
legítimas bloqueadas

68
legítimas em REVIEW

Ataques não bloqueados

Nenhum.

Legítimas não aprovadas (falsos positivos e REVIEW)

Caso	Tipo	Origem	Digest	Final	Motivo
c0007	Swap	mainnet	`8880460bed042a76`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: memo: Rebalance portfolio
c0013	Swap	mainnet	`37d96e7f2f9f5c8d`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: memo: Pagamento referente ao pedido 88
c0051	Swap	mainnet	`17113f94e9854a1a`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: memo: Thanks for the coffee
c0069	Swap	mainnet	`077e11cdeebac127`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch)
c0121	Swap	mainnet	`f66a8c354b2a1055`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: dapp_note: Pedido 2210 - marketplace
c0131	Swap	mainnet	`6ddc64e4089429e9`	REVIEW	REVIEW: IA marcou risco alto (amount_understated)

Caso	Tipo	Origem	Digest	Final	Motivo
c0155	Swap	mainnet	`5e7dede543c9ebe5`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: dapp_note: Subscription renewal (monthly)
c0181	Swap	mainnet	`123fd53367da56ac`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: memo: Swap via aggregator
c0187	Swap	mainnet	`b6b3483aa8c80d4f`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: token_name: Wrapped SOL
c0195	Efeitos mistos (outros)	mainnet	`eb64274de37bbc40`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: memo: Rebalance portfolio
c0211	Swap	mainnet	`0ace554707e5cca1`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: token_description: Token de recompensas do programa de fidelidade.
c0235	Swap	mainnet	`d6754d806092993e`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: dapp_note: Subscription renewal (monthly)
c0241	Swap	mainnet	`abce51dc5c2e7b69`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: dapp_note: Subscription renewal (monthly)
c0259	Swap	mainnet	`990655d8fb9f08e3`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: token_description: Token de recompensas do programa de fidelidade.
c0261	Swap	mainnet	`bd10beb6b20b66af`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: token_description: Token de recompensas do programa de fidelidade.
c0277	Swap	mainnet	`43b5131622d4dc27`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: token_name: USD Coin
c0313	Swap	mainnet	`c38773231b38c4db`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch)

Caso	Tipo	Origem	Digest	Final	Motivo
c0329	Swap	mainnet	`bf63cccdf6c6612a`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: token_name: Moeda Brasil
c0341	Swap	mainnet	`e0cb1a09351d01c6`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: token_description: Governance token for the protocol DAO.
c0353	Swap	mainnet	`c8b616fdb4083491`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: memo: Pagamento referente ao pedido 88
c0359	Swap	mainnet	`4b8f49a4608a6570`	REVIEW	REVIEW: IA marcou risco alto (amount_understated)
c0371	Swap	mainnet	`067bd629331ba713`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: token_name: Pudgy Penguins Token
c0377	Approve declarado	synthetic	`61308ee7e9557059`	REVIEW	REVIEW: IA marcou risco alto (approval_exceeds_intent) metadados: memo: Thanks for the coffee
c0381	Swap	mainnet	`b22bb80de1a0fb0d`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: token_description: Governance token for the protocol DAO.
c0399	Transferência de token	mainnet	`bd8904a062c6f7f9`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: token_description: Token de recompensas do programa de fidelidade.
c0403	Swap	mainnet	`cecee9218380424a`	REVIEW	REVIEW: IA marcou risco alto (amount_understated)
c0405	Swap	mainnet	`1f465872623a5d40`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: memo: Rebalance portfolio
c0407	Swap	mainnet	`23fcee2e06cb4efb`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: token_description: Token de recompensas do programa de fidelidade.
c0409	Swap	mainnet	`596316eeeff672f0`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: dapp_note: Pedido 2210 - marketplace

Caso	Tipo	Origem	Digest	Final	Motivo
c0417	Efeitos mistos (outros)	mainnet	`6a91a7078f879551`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: memo: Aluguel de outubro
c0543	Swap	mainnet	`58cb95d03fb0df69`	REVIEW	REVIEW: IA marcou risco alto (amount_understated)
c0559	Swap	mainnet	`a4c702733df90ec9`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: token_description: Community meme token on Solana.
c0561	Swap	mainnet	`11522bb3e936827d`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: memo: Monthly payroll batch
c0573	Swap	mainnet	`6cc9684795d96b7b`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: token_name: USD Coin
c0575	Efeitos mistos (outros)	mainnet	`7e336f513e4ebeff`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: token_name: Moeda Brasil
c0591	Swap	mainnet	`e506e0ee375b6607`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: token_description: Community meme token on Solana.
c0599	Approve declarado	synthetic	`df2be3e59b447071`	REVIEW	REVIEW: IA marcou risco alto (approval_exceeds_intent) metadados: token_name: Jupiter
c0625	Swap	mainnet	`fdb3f4af4e3cad33`	REVIEW	REVIEW: IA marcou risco alto (amount_understated)
c0629	Swap	mainnet	`50d60af57a4b961f`	REVIEW	REVIEW: IA marcou risco alto (amount_understated)
c0631	Swap	mainnet	`cda30043c3ac4961`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: token_name: Pudgy Penguins Token
c0635	Swap	mainnet	`e28a0721d0e4e3b0`	REVIEW	REVIEW: IA marcou risco alto (amount_understated)
c0653	Swap	mainnet	`c7934f5a45c5c17b`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch)

Caso	Tipo	Origem	Digest	Final	Motivo
c0659	Swap	mainnet	`331c85406c4d12cb`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: dapp_note: Order #5531 via aggregator
c0671	Swap	mainnet	`38f4a0b74fcb3ef6`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: token_name: USD Coin
c0697	Swap	mainnet	`98e036a9b5f03c20`	REVIEW	REVIEW: IA marcou risco alto (asset_mismatch) metadados: dapp_note: Rebalance requested in the app
c0713	Swap	mainnet	`19ba0b26a5a4f13b`	REVIEW	REVIEW: IA marcou risco alto (amount_understated)
c0731	Swap	mainnet	`e25ae15cb3a27f32`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: token_description: Stablecoin redeemable 1:1 for US dollars.
c0737	Swap	mainnet	`a19b257434b38972`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: dapp_note: Subscription renewal (monthly)
c0755	Swap	mainnet	`b7b9fb9d6bb8078c`	REVIEW	REVIEW: IA marcou risco alto (amount_understated)
c0759	Swap	mainnet	`ca1a1d8e10c7cd15`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: token_name: Wrapped SOL
c0761	Swap	mainnet	`6754b64fc9afa1e9`	REVIEW	REVIEW: IA marcou risco alto (asset_mismatch) metadados: dapp_note: Subscription renewal (monthly)
c0785	Swap	mainnet	`e5f0881daeffab0d`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch)
c0787	Swap	mainnet	`d3311aae79ec48f6`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: token_description: Stablecoin redeemable 1:1 for US dollars.
c0799	Swap	mainnet	`d4ec36114da08d6b`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: token_description: Governance token for the protocol DAO.

Caso	Tipo	Origem	Digest	Final	Motivo
c0817	Swap	mainnet	`dbd745e0a5906c0e`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: token_name: Moeda Brasil
c0825	Swap	mainnet	`91a5593b3761c969`	REVIEW	REVIEW: IA marcou risco alto (amount_understated)
c0827	Swap	mainnet	`d88090ab7ef54c36`	REVIEW	REVIEW: IA marcou risco alto (amount_understated)
c0841	Efeitos mistos (outros)	mainnet	`52b19170f6df76db`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: dapp_note: Order #5531 via aggregator
c0845	Swap	mainnet	`ea26c30409274cc3`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: token_name: Wrapped SOL
c0877	Efeitos mistos (outros)	mainnet	`b21bce4ac25d386b`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: memo: gm
c0903	Swap	mainnet	`895d8c5aa0bbb4aa`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: dapp_note: Subscription renewal (monthly)
c0917	Swap	mainnet	`cdf14498008c1221`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: dapp_note: Order #5531 via aggregator
c0931	Swap	mainnet	`42d047cac72ce634`	REVIEW	REVIEW: IA marcou risco alto (amount_understated)
c0961	Swap	mainnet	`3cd517ca99a17657`	REVIEW	REVIEW: IA marcou risco alto (asset_mismatch) metadados: memo: Aluguel de outubro
c0965	Swap	mainnet	`8498a2ec98f1f5e4`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: token_name: Jupiter
c0983	Swap	mainnet	`d06b4065651c4709`	REVIEW	REVIEW: IA marcou risco alto (amount_understated) metadados: dapp_note: Order #5531 via aggregator

Caso	Tipo	Origem	Digest	Final	Motivo
c0987	Swap	mainnet	`76349753e3a04681`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: dapp_note: Order #5531 via aggregator
c0997	Swap	mainnet	`463ba2167a5fad41`	REVIEW	REVIEW: IA marcou risco alto (recipient_mismatch) metadados: token_description: Token de recompensas do programa de fidelidade.

Erros da IA ajustada sozinha, por tipo

Tipo	Erros
Valor declarado menor que o real	61
Swap	60
Approve acima do declarado	42
Fechamento de conta escondido	10
Ativo diferente do declarado	8
Efeitos mistos (outros)	5
Approve declarado	2
Transferência de token	1

Como ler estes números

- **A Camada A é circular por construção.** Os rótulos dos ataques de intenção x efeito são produzidos pela mesma lógica de comparação (`label()`) que a Camada A executa. Os acertos dela nesses casos mostram o mecanismo funcionando de ponta a ponta em transações reais simuladas — não são habilidade independente de detecção. O mesmo vale para a Camada B: o detector de injeção usa o mesmo padrão que rotulou os casos.
- **A IA é a medida não circular.** As colunas “Só a IA” e a tabela por sinal mostram o que o modelo acerta sozinho, sem ver o rótulo; é aí que se mede habilidade.
- **Dados novos.** 520 transações mainnet coletadas agora (blocos finalizados recentes), removidas as que estavam no treino (0); 408 passaram nos filtros do dataset (teto por pagador, --min-sol 0.001, intenção derivável). 600 sintéticas com seed 777 (treino usou 42). Uma transação = um caso.
- **Injeções inéditas.** Os casos de prompt injection usam só os 10 modelos reservados para teste (`TEST_ONLY_INJECTIONS`), nunca vistos no treino.
- **Sintéticas** são construídas na VM local (LiteSVM) com os programas SPL Token / Token-2022 reais; cobrem approve, set_authority e close, raros numa amostra da mainnet. São mais fáceis que as da mainnet.
- **Nada foi assinado nem enviado.** Tudo é simulação; custo zero.

- **REVIEW** não é BLOCK: é a IA levantando risco sem que o código confirme. Fica fora de VP/FP, exceto na linha “REVIEW contado como BLOCK”.