Relatório AVAL — Benchmark Solana (demo, snapshot)

Gerado em 11/10/2026 06:30 · retrato congelado em 11/10/2026 06:19 (execução em andamento) · 4133 transações reais da mainnet + suíte de ataques (431 transações reais com intenção forjada, 760 ataques construídos e 761 gêmeos honestos) · seed 20261010 · modelo: base bf16 de Luis + LoRA veto-svm iter 300 (guloso)

Resumo: quatro números separados

0 bloqueios indevidos
(a) tráfego real: 4133 transações da mainnet

431/431
(b) ataques em transações reais bloqueados

760/760
(c) ataques construídos bloqueados · gêmeos honestos aprovados 761/761

(a) Tráfego real	Transações	ALLOW automático	REVIEW	BLOCK (falso)
Só código (camadas A + B), todas	4133	4133 (100.0%)	—	0
Com a IA (casos que a IA já avaliou)	3498	2154 (61.6%)	1344 (38.4%)	0
Decisão final, todas (sem IA ainda = só código)	4133	2789 (67.5%)	1344 (32.5%)	0

A IA avaliou 3498 de 4133 transações reais (84.6%) e 5151 de 6085 casos no total; os demais mostram o resultado só do código.

(d) Latência	Casos	p50	p95
Camadas A + B (código)	6085	16 µs	39 µs
IA de intenção (MLX, Apple M4 Pro)	5151	1.542 ms	3.931 ms
Simulação aval-svm (construídos, estado em memória)	4000	23 µs	41 µs

1. Tráfego real (mainnet, 4133 transações)

Cada transação real da mainnet, simulada pelo aval-svm, com a intenção honesta derivada dos seus efeitos. Todas deveriam ser aprovadas: aqui se mede o atrito que o Aval impõe ao uso normal.

Parcial: a IA respondeu 3498 de 4133 transações; as demais contam só o código.

0
falsos positivos (BLOCK) · taxa 0.00%

1344
REVIEW (IA levantou risco) · 32.5%

2789
aprovadas direto · 67.5%

16 µs
latência A+B p50 (p95 40 µs)

1.656 ms
latência da IA p50 (p95 4.010 ms)

64.516/s
vazão A+B por núcleo · IA 0,60/s

Por tipo de transação

Tipo (intenção derivada)	Transações	ALLOW	REVIEW	BLOCK (FP)	Taxa de REVIEW
Efeitos mistos (outros)	1674	1249	425	0	25.4%
Swap	1195	325	870	0	72.8%
Transferência de token	685	643	42	0	6.1%
Transferência de SOL	482	475	7	0	1.5%
Criação de conta	92	92	0	0	0.0%
Fechar conta	5	5	0	0	0.0%

Por que a IA pediu REVIEW

Sinal nomeado pela IA	Casos
Troca de destinatário	771
Valor declarado menor que o real	493
Ativo diferente do declarado	78
recipient_null	2

Valor movimentado (cotação CoinGecko de 2026-10-10T15:16:55-03:00): aprovadas US$ 154.692,58, em REVIEW US$ 49.362,22, bloqueadas US$ 0,00. 3510 de 4133 transações com todas as cotações; tokens sem cotação contam US$ 0.

Coleta: blocos finalizados recentes via Helius (plano grátis, 9 req/s), 394 blocos, 39204 transações simuladas (27874 falharam na simulação contra o estado atual, 5059 sem efeito no signatário), 6313 registros, 54807 chamadas RPC (3899 respostas 429 e 8 respostas truncadas, refeitas). Filtros: 6313 registros → 4564 utilizáveis; descartes {"below_min_sol": 1099, "payer_cap": 650}; teto de 20 por pagador (650 descartadas por ele, 3012 pagadores distintos). 431 registros sorteados antes foram para a suíte de ataques (conjuntos disjuntos).

2. Suíte de ataques

Ataques nunca se misturam com o tráfego real. Duas fontes, mostradas lado a lado: transações construídas na VM local e transações reais da mainnet com uma intenção forjada.

Conjunto	Ataques	Bloqueados	REVIEW	Não bloqueados (ALLOW)	Taxa de bloqueio	Valor protegido
Construídos (VM local)	760	760	0	0	100.00%	sem cotação
Transação real, intenção forjada	431	431	0	0	100.00%	US$ 17.693,42

Gêmeos honestos dos construídos: 761 casos, 0 BLOCK (falso positivo), 0 REVIEW, 761 ALLOW.

Por tipo de ataque

Tipo	Construídos	Bloqueados (camada)	Escaparam	Reais forjados	Bloqueados (camada)	Escaparam
Troca de destinatário	148	148 (A:148)	0	88	88 (A:88)	0
Valor declarado menor que o real	63	63 (A:63)	0	89	89 (A:89)	0
Ativo diferente do declarado	63	63 (A:63)	0	90	90 (A:90)	0
Approve acima do declarado	148	148 (A:148)	0	0	—	—
Troca de autoridade escondida	63	63 (A:63)	0	0	—	—
Approve escondido	63	63 (A:63)	0	0	—	—
Fechamento de conta escondido	63	63 (A:63)	0	2	2 (A:2)	0
Prompt injection (modelos inéditos)	149	149 (B:149)	0	162	162 (B:162)	0

Ataques não bloqueados

Nenhum.

IA de intenção (medida não circular)

Conjunto	Esperado	Casos	IA ajustada: acertos	IA ajustada: nomeou o sinal	IA original (amostra): acertos
Tráfego real	ALLOW	4133	2154/3498 (61.6%)	—	163/163 (100.0%)
Transação real, intenção forjada	BLOCK	431	342/366 (93.4%)	320 (87.4%)	0/40 (0.0%)
Construídos (VM local)	ALLOW	761	644/644 (100.0%)	—	40/40 (100.0%)
Construídos (VM local)	BLOCK	760	504/643 (78.4%)	494 (76.8%)	0/40 (0.0%)

Acerto da IA sozinha: *high* em ataques, *low* em legítimas. A IA original foi rodada só numa amostra estratificada de 283 casos (proporcional por conjunto × esperado, com piso por estrato).

Latência

Etapa	Casos medidos	p50	p95	Média
Camada A — comparação intenção x efeitos simulados (código)	6085	9 µs	25 µs	12 µs
Camada B — detector de injeção (código)	6085	7 µs	18 µs	56 µs
Camada C — IA de intenção (MLX, Apple M4 Pro)	5151	1.542 ms	3.931 ms	1.977 ms
Simulação aval-svm (construídos, estado em memória)	4000	23 µs	41 µs	26 µs

A simulação das transações da mainnet não é cronometrada aqui: na coleta ela inclui a busca de estado no RPC sob o limite de 9 req/s do plano grátis, o que mede a fila e não o Aval.

Limitações

- **Não são 20 mil transações.** Este é um retrato congelado de uma execução em andamento: 4133 transações reais e 431 ataques em transações reais até 11/10/2026 06:19. O relatório final (meta ≥ 20 mil transações reais) sai quando a coleta e a IA terminarem.
- **Como os ataques foram feitos.** Nenhum ataque é um golpe real observado na mainnet. Os “reais forjados” são transações reais legítimas cuja intenção declarada foi alterada por código (destinatário, valor, ativo, approve ou autoridade escondidos, injeção nos metadados). Os “construídos” são transações de permissão de token montadas na VM local (seed 9001) com os programas SPL reais. As injeções usam só os modelos reservados para teste.

- **A checagem de rótulo é circular.** O gabarito dos ataques sai da mesma função de comparação (`label()`) que a Camada A executa, e o detector da Camada B usa o mesmo padrão que gerou as injeções. Os 100% de bloqueio mostram o mecanismo funcionando em transações reais simuladas, não habilidade independente de detecção. Pelo mesmo motivo, 0 falso positivo do código no tráfego real é esperado: a intenção honesta é derivada dos próprios efeitos.
- **A IA pede REVIEW demais em swaps.** Nos swaps reais que ela avaliou, 870 de 1003 (86.7%) foram para REVIEW — quase sempre alegando valor menor que o real ou troca de destinatário, o que não acontece (o código confirma). É atrito de UX, não bloqueio: pela regra da equipe a IA só levanta risco, e sem `injected_instruction` isso vira REVIEW, nunca BLOCK.
- **Simulação contra estado atual.** Cada transação foi re-simulada contra o estado de agora; as que falham nessa repetição (a maioria, por estado já consumido) ficam fora da amostra, o que favorece tipos de transação estáveis.

Como ler estes números

- **Dois números, nunca somados.** O tráfego real mede atrito (falsos positivos e REVIEW em uso normal); a suíte de ataques mede proteção. Uma "acurácia geral" misturando os dois dependeria só da proporção escolhida.
- **A Camada A é circular por construção.** Os rótulos dos ataques de intenção x efeito vêm da mesma lógica de comparação (`label()`) que a Camada A executa; o mesmo vale para a Camada B e o padrão de injeção. Os bloqueios delas mostram o mecanismo funcionando de ponta a ponta em transações reais simuladas, não habilidade independente.
- **A IA é a medida não circular.** A tabela da IA mostra o que o modelo acerta sozinho, sem ver o rótulo.
- **Zero falso positivo no tráfego real é esperado pela construção**: a intenção honesta é derivada dos próprios efeitos simulados. O que esse conjunto testa de fato é se metadados comuns e a IA geram atrito (REVIEW).
- **REVIEW** não é BLOCK: é a IA levantando risco sem confirmação do código (regra "o LLM opina, o código decide": *high* + `injected_instruction` → BLOCK; outro *high* → REVIEW).
- **Dados novos.** Nenhuma transação de arquivos anteriores (treino e benchmark de 1000) entra aqui; os ataques construídos usam seed 9001 (treino 42, benchmark anterior 777); as injeções vêm só de `TEST_ONLY_INJECTIONS`.
- **Nada foi assinado nem enviado.** Tudo é simulação; custo zero (plano grátis do RPC).